

Cleaning Log

Progetto 2 — Retail Store Sales

Dataset: Kaggle - Retail Store Sales: Dirty for Data Cleaning · Strumento: Power Query (Excel)

Questo documento raccoglie l'intero processo di pulizia del dataset, in ordine logico. Per ogni colonna trattata sono descritti: il problema iniziale (diagnosi via profiling), la strategia scelta, i passi esatti eseguiti in Power Query, e la decisione con la sua motivazione. Le colonne originali sono state conservate ovunque una trasformazione modifichi i dati (suffisso _raw), per garantire tracciabilità completa e audit.

1. Impostazione iniziale e profiling

1.1 Caricamento del dataset

1. Trasformato il file CSV in Tabella Excel (Ctrl+T) prima dell'import.

2. Dati -> Da tabella/intervallo per aprire l'Editor di Power Query.

Dimensione dataset: 12.575 righe, 11 colonne originali.

1.2 Attivazione strumenti di profiling

Nella scheda Visualizza, attivate tre opzioni fondamentali per la diagnostica:

- Colonna qualità (barre verde/rosso/grigio: validi/errore/vuoto per colonna)
- Colonna distribuzione (istogramma dei valori)
- Profilo colonna (pannello statistiche in basso)

In basso a sinistra, cliccato su "Profilatura basata sulle prime 1000 righe" e selezionato "Profilatura basata sull'intero set di dati" - fondamentale per non lavorare su un campione.

1.3 Diagnosi iniziale: mappa dei problemi

Il profiling completo su tutte le colonne ha rivelato:

- Item: 10% vuoti (1.213 righe con stringa vuota) - 201 valori distinti attesi 200
- Price Per Unit: 5% vuoti
- Quantity: 5% vuoti
- Total Spent: 5% vuoti + sospetta incoerenza con Price x Quantity
- Discount Applied: 33% vuoti (colonna booleana True/False)
- Transaction ID, Customer ID, Category, Payment Method, Location, Transaction Date: puliti al 100%

2. Verifiche preliminari sui pattern

Prima di qualsiasi correzione, verifica dei pattern nei dati per giustificare le scelte di pulizia con numeri, non a occhio.

2.1 Pattern Total Spent vs Price Per Unit x Quantity

Ipotesi: sospetto di un fattore di scala sistematico tra Total Spent e il prodotto Price x Quantity.

Verifica eseguita:

1. Aggiungi colonna -> Colonna personalizzata: [Price Per Unit] * [Quantity], nome Calculated Total.
2. Aggiungi colonna -> Colonna personalizzata: [Calculated Total] / [Total Spent], nome Calc_to_Total_Ratio.
3. Modificato tipo di Calc_to_Total_Ratio a numero decimale, poi profilata la colonna.

Risultato: Minimo=10, Massimo=10, Media=10, Deviazione standard=0. Pattern sistematico al 100%, non errore sporadico.

Decisione: Total Spent tenuto come colonna di riferimento per le analisi (è il nome esplicito "totale della transazione" nel dataset). Calculated Total e Calc_to_Total_Ratio conservate come colonne di audit, dimostrano il controllo di qualità eseguito. Nessuna correzione applicata - il pattern è probabilmente una scelta di generazione del dataset (unità di misura o fattore di scala), non un errore da correggere.

2.2 Duplicati su Transaction ID

Verifica: cliccato sull'intestazione Transaction ID, controllato pannello Statistiche colonna.

Risultato: Conteggio 12.575, Valori distinti 12.575, Valori univoci 12.575 - tutti coincidono.

Decisione: Zero duplicati su Transaction ID. Non verificati duplicati su combinazione di altri campi (rischio basso su dataset sintetico); scelta di fermarsi qui dichiarata esplicitamente.

2.3 Range plausibili su Price Per Unit e Quantity

Verifica: pannello Statistiche colonna su ciascuna.

- Price Per Unit: Min 50, Max 410, Media 233,66, Dev.std 107,4 - 26 valori distinti a step di 15 (griglia regolare)
- Quantity: Min 10, Max 100, Media 55,4, Dev.std 28,6 - 11 valori distinti a step di 10 (griglia regolare)

Decisione: Nessun valore negativo, zero, o outlier estremo. Nessuna azione di pulizia necessaria sui range. Le griglie regolari suggeriscono generazione sintetica strutturata.

3. Pulizia colonna Item

3.1 Diagnosi approfondita

- Vuoti: 1.213 righe (10%), tecnicamente stringhe vuote (""), non null
- Valori distinti: 201 (200 articoli reali + 1 categoria "stringa vuota")
- Pattern nome: Item_N_CATEGORIA (es. Item_10_PAT)

3.2 Verifica univocità Category + Price Per Unit -> Item

Ipotesi: se Category+Price identificano univocamente Item, si può dedurre Item nei vuoti.

Verifica in una query duplicata separata (LOOKUP_category_price_item):

1. Clic destro su retail_store_sales -> Duplica. Rinominata copia in LOOKUP_category_price_item.
2. Filtro colonna Item: deselezionato (vuoto) per tenere solo righe con Item valido (11.362 righe).
3. Selezionate colonne Category, Item, Price Per Unit (Ctrl+clic). Home -> Rimuovi colonne -> Rimuovi altre colonne.
4. Trasforma -> Raggruppa per (Avanzate): raggruppamenti Category + Price Per Unit; aggregazione Item_distinti = Conteggio righe distinte.

Risultato: 200 righe (8 categorie x 25 prezzi), Item_distinti sempre = 1. Deviazione standard 0.

Conclusione: Category + Price identificano Item in modo univoco al 100%. Deduzione possibile su ogni riga con questi due valori presenti.

3.3 Costruzione tabella di lookup

Estesa la stessa query LOOKUP_category_price_item aggiungendo anche il valore vero di Item:

1. Nel Raggruppa per (avanzate), aggiunta seconda aggregazione: nome Item_Valore, operazione Minimo, colonna Item.
2. Risultato: tabella 200 righe con Category, Price Per Unit, Item_distinti (=1), Item_Valore (nome vero dell'articolo).
3. Opzionalmente rimossa la colonna Item_distinti dopo la verifica - resta solo Category, Price Per Unit, Item_Valore.

3.4 Merge con la query principale

1. Tornata su retail_store_sales. Home -> Merge di query.

2. Tabella principale: Ctrl+clic su Category, poi Price Per Unit (in quest'ordine).
3. Tabella lookup: selezionata LOOKUP_category_price_item. Ctrl+clic su Category, poi Price Per Unit (stesso ordine).
4. Tipo di join: Sinistra esterna (default).
5. Corrispondenza: 11.966 righe su 12.575 - coerente (le righe non corrispondenti sono quelle dove manca anche Price Per Unit).
6. Espansione: cliccata icona espansione sulla nuova colonna, tenuto solo Item_Valore, disattivato prefisso.

3.5 Verifica residuo e etichettatura

Filtrato Item_Valore su null (609 righe residue). Controllato che tutte queste 609 righe abbiano Price Per Unit vuoto: verifica positiva al 100%. Rimosso il filtro.

1. Clic destro su Item_Valore -> Sostituisci valori. Valore da trovare: null. Sostituisci con: Unknown_Item.
- Risultato: Item_Valore 100% valida, 0 vuoti, 201 valori distinti (200 articoli veri + 1 etichetta Unknown_Item).*

3.6 Finalizzazione

1. Rimossa la vecchia colonna Item originale (con le stringhe vuote) - in alternativa, la si può rinominare in Item_raw per audit.
2. Rinominata Item_Valore in Item.

Sintesi cleaning log Item: 1.213 righe con stringa vuota inizialmente. Verificato che Category + Price Per Unit identificano Item in modo univoco (dev.std=0 su 200 combinazioni). Creata tabella di lookup dedicata. Merge sulla query principale con join a sinistra: risolte 604 righe tramite deduzione. Le restanti 609 righe non erano deducibili perché mancava anche Price Per Unit (verificato: 609/609 corrispondenza esatta). Queste sono state etichettate esplicitamente "Unknown_Item" invece di lasciate vuote, per rendere visibile la mancanza nelle analisi successive. Risultato finale: colonna Item 100% completa.

4. Pulizia colonna Price Per Unit

4.1 Diagnosi e strategia

- Vuoti: 5% (629 righe)
- Strategia: stesso schema di Item, ma nella direzione inversa - Item ora popolato (dopo la pulizia precedente) può dedurre Price

4.2 Verifica univocità Item -> Price Per Unit

Costruita seconda tabella di lookup in una query separata:

1. Duplicata retail_store_sales (o creata query nuova filtrata). Rinominata LOOKUP_Item_price.
2. Filtro colonna Price Per Unit: deselezionato null.
3. Rimosse altre colonne, tenute solo Item e Price Per Unit.
4. Raggruppa per (Avanzate): raggruppamento Item; aggregazione 1 = Prezzi_distinti (Conteggio righe distinte, colonna Price Per Unit); aggregazione 2 = Price_Valore (Minimo su Price Per Unit).

Risultato: 200 righe, Prezzi_distinti sempre = 1, Price_Valore contiene il prezzo unico per ogni articolo.

Conclusione: Item determina Price Per Unit in modo univoco al 100%. Deduzione affidabile.

4.3 Merge con la query principale

1. Home -> Merge di query.
2. Chiave: Item (una sola colonna). Lookup: LOOKUP_Item_price, chiave Item_Valore.
3. Join: Sinistra esterna. Espansione: tenuto solo Price_Valore, disattivato prefisso.

4. Risultato: Price_Valore 95% valida (i vuoti residui coincidono con le righe Item = "Unknown_Item", per cui non esiste articolo di riferimento).

4.4 Finalizzazione con conservazione audit

1. Rinominata la vecchia Price Per Unit originale in Price Per Unit_raw (conservata per audit).
2. Rinominata Price_Valore in Price Per Unit_clean.

Nessuna sostituzione dei null residui: quando Item = "Unknown_Item", il prezzo è genuinamente sconosciuto e non deducibile - null è la scelta corretta.

Sintesi cleaning log Price Per Unit: 5% vuoti (~629 righe). Verificato che Item determina il prezzo in modo univoco (dev.std=0 su 200 articoli). Dedotto tramite lookup Item -> Price per tutte le righe con Item noto. Colonna originale conservata come Price Per Unit_raw per audit; colonna pulita Price Per Unit_clean usata per le analisi. Vuoti residui coincidono con le righe "Unknown_Item" (non recuperabili in nessuna direzione).

5. Pulizia colonna Discount Applied

5.1 Diagnosi approfondita

- Vuoti: 33% (4.199 righe) - il buco più grande del dataset
- Vero: 4.219, Falso: 4.157, Vuoto: 4.199 - tre fette quasi esattamente uguali (1/3 ciascuna)
- Tipo colonna: booleano (True/False)

5.2 Verifica pattern del vuoto

Ipotesi: se il vuoto è distribuito casualmente rispetto ad altre colonne (Payment Method, Location), e' generato in modo random - se è concentrato su un canale/segmento, è un problema di raccolta dati.

Verifica:

1. Filtro Discount Applied: tenuto solo (Null) - isolate 4.199 righe.
2. Cliccato su Payment Method, guardata la Distribuzione dei valori nel pannello in basso.

Risultato: le tre barre (Cash, Credit Card, Digital Wallet) sono visivamente identiche - vuoto distribuito uniformemente rispetto al metodo di pagamento.

3. Rimosso il filtro (fondamentale, altrimenti la query resta bloccata sul sottoinsieme).

Conclusione: Il vuoto è distribuito casualmente, e la spartizione ~1/3 True, ~1/3 False, ~1/3 null suggerisce generazione deliberata (missing completamente casuale). NON è un problema di raccolta dati concentrato, e nemmeno un valore recuperabile da altre colonne. La scelta di sostituire null con FALSE sarebbe scorretta - abbasserebbe artificialmente il tasso di sconto calcolato.

5.3 Creazione colonna con etichetta esplicita

Metodo scelto: colonna condizionale (più affidabile del "Sostituisci valori" su colonne booleane con null).

1. Aggiungi colonna -> Colonna condizionale.
2. Nome nuova colonna: Discount_Status.
3. Se: colonna Discount Applied, operatore "e uguale a", valore: scrivere letteralmente "null" (funziona in questo dialogo, diversamente da "Sostituisci valori").
4. Allora (output): Not specified.
5. Else: selezionare l'opzione "Colonna" (non "Valore"), scegliere Discount Applied - mantiene True/False dove erano.
6. OK. Risultato: nuova colonna Discount_Status con 100% valida (True, False, Not specified come 3 valori distinti).

5.4 Correzione tipo colonna

La nuova colonna nasceva con tipo Any (icona 123ABC) perché mista - va forzata esplicitamente:

- 1. Clic destro sull'intestazione Discount_Status -> Tipo di dati -> Testo.
- 2. I valori booleani vengono convertiti nelle stringhe "true"/"false" (minuscolo).

5.5 Finalizzazione con conservazione audit

- 1. Rinominata la vecchia colonna booleana originale Discount Applied in Discount Applied_raw (conservata per audit).
- 2. Rinominata Discount_Status in Discount Applied_clean.

Sintesi cleaning log Discount Applied: 4.199 vuoti (~33%), distribuzione uniforme rispetto al metodo di pagamento e vicina a un terzo esatto insieme a True/False - pattern coerente con missing completamente casuale (probabile scelta di generazione del dataset). Sostituiti con etichetta esplicita "Not specified" tramite Colonna condizionale, MAI forzati a False per non alterare il tasso di sconto calcolato. Colonna forzata a tipo Testo per coerenza. Colonna originale conservata come Discount Applied_raw.

6. Colonna Quantity: decisione motivata di non intervento

Vuoti: 5% (~629 righe). Nessuna azione tecnica applicata.

Motivazione: A differenza di Item e Price Per Unit, non esiste alcuna colonna nel dataset che determini in modo affidabile "quanto un cliente ha comprato" - Quantity è una scelta d'acquisto, non un attributo fisso di prodotto/transazione. Qualsiasi tentativo di riempirla (media, valore fisso, deduzione) sarebbe un'invenzione mascherata da dato. La scelta più onesta è lasciare i null visibili.

Conseguenza: Le analisi che richiedono Quantity (es. volumi venduti totali) escluderanno esplicitamente le 629 righe con Quantity null. L'impatto sarà documentato nelle singole analisi quando rilevante.

7. Colonna Transaction Date: verifica di controllo

Verifica finale della colonna, mai stata protagonista di correzioni durante la pulizia.

- 1. Cliccato sull'intestazione Transaction Date.
- 2. Controllo icona colonna: già calendario (Data) - tipo corretto.
- 3. Controllo pannello Statistiche colonna: Conteggio 12.575, Errore 0, Vuoto 0.
- 4. Controllo range: Minimo e Massimo entro 2022-2025, coerente con la descrizione del dataset. Nessuna data assurda (es. 1900 o 2099) che indichi formati misti mal interpretati.

Decisione: Transaction Date pulita fin dall'origine. Nessuna azione necessaria.

8. Riepilogo finale della pulizia

Colonna	Problema iniziale	Metodo applicato	Esito
Item	10% vuoti (1.213)	Deduzione da Category+Price (604 righe) + etichetta Unknown_Item (609 residui)	100% completa
Price Per Unit	5% vuoti (~629)	Deduzione da Item; originale conservata come raw	95% completa*
Total Spent	Pattern x10 vs Price*Quantity	Nessuna correzione; pattern documentato, colonne audit conservate	Chiuso
Discount Applied	33% vuoti (4.199)	Etichetta Not specified via Colonna condizionale; mai False	100% completa
Quantity	5% vuoti (~629)	Nessuna imputazione - non deducibile; lasciata null	Documentato
Transaction Date	-	Verificato tipo Data e range plausibile	Nessuna azione
Transaction ID	-	Verificato zero duplicati	Chiuso
Range Price/Quantity	-	Verificato nessun outlier/negativo/zero	Chiuso

*Vuoti residui coincidono con Item = "Unknown_Item" - non recuperabili in nessuna direzione.

Struttura finale del file

Query nel file Excel al termine della pulizia:

- retail_store_sales - query principale, 12.575 righe, con colonne originali + _raw + _clean + audit

- LOOKUP_category_price_item - tabella di supporto per deduzione Item (200 righe)
- LOOKUP_Item_price - tabella di supporto per deduzione Price Per Unit (200 righe)
- retail_store_sales_disc... - query di verifica sul filtro Discount Applied (opzionale, di controllo)

Principi metodologici applicati

- Verifica prima di correggere: ogni intervento è preceduto da un pattern verificato con numeri (dev.std=0, conteggi esatti, percentuali).
- Trasparenza via colonne _raw: le trasformazioni non cancellano il dato originale ma lo affiancano, per audit e verifica.
- Etichette esplicite invece di silenzi: 'Unknown_Item', 'Not specified' rendono visibile la mancanza nelle analisi.
- Onesta sui limiti: dove non c'è evidenza (Quantity), null resta null - mai imputazione arbitraria.
- Duplicazione preventiva: ogni tabella di supporto è costruita in una query separata (mai lavorare direttamente sulla query principale).